



# Analyse Comparative de la Recherche en Oncologie

## Réalité Clinique vs. Mortalité Mondiale

Pipeline ETL complète

Focus sur cinq types de cancers majeurs : Poumon, Sein, Pancréas, Leucémie et Prostate.

Problématique: "L'investissement en recherche est-il corrélé à la gravité réelle des maladies ?"



# Architecture du Projet




## Collecte

Scraping (ClinicalTrials.gov), API (PubMed), Open Data (OMS)



## Transformation

Script Python, Nettoyage, Jointure (Pandas)



## Stockage

Base de données Cloud (Supabase / PostgreSQL)



## Visualisation

Notebook Jupyter (Matplotlib)



# Scraping De ClinicalTrials.gov

## Défi Technique

### Problème

- Structures dynamiques

### Solution : Tout scrapper !

Selenium interagit comme un utilisateur réel, on aspire TOUT le texte brut pour contourner les erreurs de sélecteurs.

### Performance

Pagination automatisée sur 30 pages par cancer, avec 10 essais par page, permettant la récupération de plus de 1500 essais cliniques.

## Robustesse

### Auto-Healing

Vérifie à chaque action que le navigateur répond

```
self.driver.current_url  
except:  
    print("\n⚠️ ALERTE : Le navigateur ne répond plus ! Redémarrage d'urgence...")
```

### Sauvegarde Incrémentale

Enregistrement progressif des données pour minimiser la perte et optimiser le temps de traitement.

```
if compteur_total % 10 == 0:  
    self.sauvegarder()
```

### Contournement des Blocages



Imitation du temps de lecture d'un humaine

```
time.sleep(2)
```

# Enrichissement des Données : API & Open Data OMS

Scripts `2_ApiSearch.py` & `3_Nettoyage.py`

Pour contextualiser les essais cliniques, nous avons enrichi notre dataset avec des informations provenant de sources académiques et de santé publique.



# Pipeline de nettoyage : Sources multiples vers données exploitable

## Sources de données intégrées

### Données OMS

Mortalité par cancer (2022) - nettoyage et tri par décès décroissants pour établir la gravité.

### API PubMed

Publications scientifiques 2024 par type de cancer - indicateur de l'intérêt académique.

### NCI Budget

Financement de la recherche américaine 2023 - extrait et converti en USD pour une base comparable.

### Google Trends

Visibilité médiatique par pays - scores d'intérêt moyen pour la perception publique.

## Transformations effectuées

### Mapping des Nomenclatures

Uniformisation des terminologies (ex: "Trachea bronchus and lung" → "Lung Cancer").

### Fusion des Datasets

Regroupement des données via des colonnes clés communes pour une vue intégrée.

### Calcul de Métriques

Définition de nouvelles métriques, comme les publications pour 1000 décès.

### Nettoyage des Formats

Standardisation des formats monétaires (\$, virgules) en valeurs numériques flottantes.

# Garantir la fiabilité : Nettoyage des 5000+ essais cliniques

## 1 Extraction et Nettoyage des Identifiants

- Utilisation de Regex pour isoler les **NCT IDs** des URLs.
- Parsing intelligent des titres pour standardiser les informations d'étude.

## 2 Déduplication Massive

Mise en œuvre d'un processus strict basé sur l'**ID d'Essai Clinique** unique, garantissant un dataset sans doublons et la conservation de la première occurrence.

## 3 Géolocalisation Précise des Essais

- Fonctionnalité d'extraction pays/région via une base de plus de 800 mots-clés.
- Classification en 8 grandes zones géographiques pour analyser la répartition des efforts de recherche par type de cancer.



# Stockage Cloud : Persistance des Données avec Supabase

Script 4\_Supabase.py

Supabase, une plateforme "open source Firebase alternative", a été choisie pour héberger notre base de données PostgreSQL dans le cloud, offrant scalabilité et accessibilité.



## PostgreSQL Cloud

Utilisation d'une instance PostgreSQL gérée par Supabase pour une solution de base de données robuste et évolutive.



## Chargement par Batchs

Chargement des données par paquets de 1000 lignes pour optimiser les performances et minimiser la charge sur la base.



## Gestion d'Erreurs & Logs

Implémentation d'une gestion d'erreurs détaillée et de logs pour assurer l'intégrité du processus de chargement et le débogage facile.

# Indicateurs Clés (KPI)

Objectif: Quantifier et comparer l'effort de recherche, le financement et la visibilité des cancers au regard de leur impact sanitaire.



## Essais Cliniques par Type de Cancer

Nombre d'essais recensés par cancer, identifiant les domaines de recherche prioritaires.

cancer	trials_count
Pancreatic Cancer	300
Lung Cancer	300
Prostate Cancer	300
Leukemia	300
Breast Cancer	299



## Budget de Recherche (NCI)

Analyse des budgets moyens, min. et max. par cancer, révélant la répartition des financements.

avg_budget_mil	min_budget_mil	max_budget_mil
350.44	246	542





## Indicateur de Priorité

Ratio **mortalité / publications scientifiques** : une valeur élevée suggère un cancer sous-recherché.

cancer	mortality_2015	publications_2015	deaths_per_publication
Lung Cancer	1817469	17299	105.0620845135556969
Pancreatic Cancer	467409	4665	100.1948553054662379
Prostate Cancer	397430	9628	41.2785625259659327
Leukemia	305405	9988	30.5771926311573889
Breast Cancer	666103	24582	27.0971849320641120



# Intérêt Média<sup>tique</sup> et Budget de Recherche

Analyse comparative des investissements





# Répartition des Ressources et Efficacité

Budget par décès et allocation NCI




# Distribution Géographique et Intensité de Recherche

Analyse régionale et effort académique



# Analyse Comparative Régionale et Corrélation Clé

Disparités géographiques et relation mortalité-recherche



## 1. Biais Média tique et "Effet de Visibilité"

Le cancer du sein bénéficie d'une **triple surreprésentation** :

- Intérêt médiatique élevé (24,1)
- Budget le plus important (\$542M)
- Intensité de recherche la plus forte (36,9 publications/1000 décès)

## 2. La Grande Injustice : Le Cancer du Poumon

Malgré sa **mortalité la plus élevée**, le cancer du poumon souffre d'un **triple handicap** :

- Intérêt médiatique le plus faible (18,8)
- Investissement par décès dérisoire (\$0,2k)
- Intensité de recherche la plus basse (9,5 publications/1000 décès)

## 3. Cancer Pancréatique : L'Oublié Mortel

Avec un **taux de survie à 5 ans inférieur à 10%**, c'est l'un des cancers les plus létaux. Pourtant :

- Investissement par décès modeste (\$0,5k)
- Intensité de recherche faible (10,0 publications/1000 décès)

## 4. Inégalités Géographiques

La recherche clinique est massivement concentrée dans les pays à revenu élevé (USA, Europe, Canada), créant un **double problème** :

- Les populations des pays en développement n'accèdent pas aux innovations
- Les diversités génétiques et environnementales sont sous-étudiées, limitant la généralisation des résultats



# Conclusion : Réponse à la Problématique

L'analyse démontre l'existence de **multiples biais structurels** créant des inégalités majeures dans l'innovation médicale :

## 1. Biais Médiatique

- Le cancer du sein reçoit une attention disproportionnée grâce à des décennies de mobilisation associative (Ruban Rose, Octobre Rose), créant un cercle vertueux de financement et de recherche qui ne reflète pas strictement sa gravité sanitaire relative.

## 2. Biais Économique

- Les cancers "rentables" (avec des populations importantes de survivants à long terme nécessitant des traitements continus) attirent davantage l'investissement pharmaceutique que les cancers rapidement létaux comme le cancer pancréatique.

## 3. Biais Géographique

- La concentration de la recherche dans les pays riches crée une "science à deux vitesses" excluant 85% de la population mondiale, perpétuant les inégalités sanitaires globales.

# Pistes d'Amélioration et Perspectives Futures

## 1. Élargir le Périmètre d'Analyse

- Intégrer d'autres cancers (colorectal, ovaire, mélanome, etc.) pour une vision plus complète et identifier d'autres déséquilibres.

## 2. Analyser l'Impact sur les Patients Vivants

- Évaluer le nombre de personnes vivantes touchées par chaque cancer, pas seulement la mortalité. Cela révélerait l'impact réel sur la qualité de vie et la charge de morbidité.

## 3. Intégrer les Coûts Sociétaux

- Analyser le coût économique indirect (perte de productivité, soins palliatifs) pour une allocation plus équitable des ressources.

## 4. Suivi Temporel et Prédictif

- Mettre en place une surveillance continue du pipeline pour détecter les tendances émergentes et anticiper les besoins futurs en recherche.